

Optimización espacial de Needleman–Wunsch y filogenia molecular del citocromo c

Franklin Espinoza Pari

Código: 20210135D franklin.espinoza.p@uni.pe

github.com/franklinep/-CC0F3-Biologia_Computacional

Mayo de 2026

Resumen

Sobre la implementación OO de Needleman–Wunsch (NW) y Smith–Waterman de la PC2 se abordan dos problemas del parcial. (i) El algoritmo de **Hirschberg** reduce la memoria de NW de $O(mn)$ a $O(\min(m, n))$ conservando tiempo $O(mn)$; validado sobre el CDS CYCS humano vs. ratón (318 bases, NCBI) y benchmark hasta 6400 bases: NW clásico llega a **1.4 GiB**, Hirschberg permanece en baseline. (ii) Con identidad NW+BLOSUM62 entre 6 ortólogos de citocromo c (Humano, Chimpancé, Gorila, Ratón, Gallina, Atún) se construye una matriz 6×6 y un dendrograma: el árbol agrupa correctamente los primates y separa el atún como outgroup, pero falla en la topología interna mamíferos/aves por saturación del marcador. Los 15 pares se validan contra Bio.Align.PairwiseAligner con coincidencia exacta de score e identidad.

1. Introducción

El alineamiento de pares es la primitiva sobre la que se construye casi toda la bioinformática comparativa. En la PC2 implementamos NW (global) y SW (local) con matrices SIMPLE/PAM/-BLOSUM siguiendo los patrones *Template Method* y *Strategy* [8]. Esa base se reutiliza aquí **sin modificación**. **Proyecto 1:** el límite práctico de NW no es el tiempo sino la *memoria* —una matriz $10^5 \times 10^5$ ocupa ~ 40 GiB en enteros—, lo que motiva el algoritmo de Hirschberg [1] (1975), que alcanza $O(\min(m, n))$ memoria por divide-and-conquer conservando $O(mn)$ tiempo. **Proyecto 2:** la matriz de distancias por pares construida con NW permite reconstruir filogenias por aglomeración jerárquica; aplicamos esta idea clásica al citocromo c, el caso de estudio histórico de Margaret Dayhoff [3]. **Objetivos:** (a) implementar Hirschberg y validar el score contra NW; (b) cuantificar la diferencia de memoria con `memory_profiler`; (c) construir una matriz 6×6 y un dendrograma con 6 ortólogos reales y discutir su concordancia con la filogenia conocida.

2. Marco teórico

2.1. Recurrencia de Needleman–Wunsch

La matriz $H \in \mathbb{Z}^{(m+1) \times (n+1)}$ se llena con la recurrencia

$$H_{i,j} = \max \begin{cases} H_{i-1,j-1} + s(\text{seq}_1[i], \text{seq}_2[j]) \\ H_{i-1,j} + g \\ H_{i,j-1} + g \end{cases}, \quad H_{i,0} = ig, \quad H_{0,j} = jg, \quad (1)$$

con score óptimo $H_{m,n}$. El traceback estandar reconstruye un alineamiento óptimo en $O(m+n)$ pasos pero requiere conservar la matriz completa: $O(mn)$ en tiempo y memoria.

2.2. Hirschberg: NW en $O(\min(m, n))$ memoria

La observación clave es que $H_{i,j}$ sólo depende de la fila anterior y la celda inmediatamente a la izquierda, así que el *score* puede calcularse manteniendo únicamente dos filas (memoria $O(n+1)$, más aún $O(\min(m, n) + 1)$ si elegimos como “columna” la dimensión más corta). El problema es que esto no permite reconstruir el alineamiento.

Hirschberg [1] resuelve el traceback con una recurrencia divide-and-conquer:

1. Particionar seq_1 por su mitad $i^* = m/2$.
2. Calcular dos vectores de scores con la primitiva $O(n)$:

$$F[j] = \text{NW_score}(\text{seq}_1[:i^*], \text{seq}_2[:j])$$

$$B[j] = \text{NW_score}(\text{reverse}(\text{seq}_1[i^* :]), \text{reverse}(\text{seq}_2[j :]))$$

3. Encontrar $j^* = \arg \max_j (F[j] + B[n - j])$. El alineamiento óptimo pasa por la celda (i^*, j^*) .
4. Recurrir sobre $(\text{seq}_1[:i^*], \text{seq}_2[:j^*])$ y $(\text{seq}_1[i^* :], \text{seq}_2[j^* :])$, concatenando los resultados.

La recurrencia del tiempo es $T(m, n) = T(m/2, j^*) + T(m/2, n - j^*) + O(mn)$, cuya solución es $T(m, n) = O(mn)$ (el trabajo cada nivel se divide a la mitad de la dimensión m , pero suma n completo; geométricamente: $mn + mn/2 + mn/4 + \dots \leq 2mn$). La memoria pico es $O(\min(m, n))$ porque en cada nivel de la recursión sólo se mantienen dos vectores de tamaño $\leq n$ y la profundidad máxima es $O(\log m)$. La constante temporal de Hirschberg es aproximadamente $2 \times$ la de NW clásico, intercambio que compensa con creces la mejora en memoria cuando mn es grande.

2.3. Distancia evolutiva a partir de alineamientos

Dado el alineamiento global óptimo, la identidad por par es $p = M/L$ ($M = \text{matches}$, $L = \text{longitud del alineamiento}$). Definimos la distancia $d = 100(1 - p)$; no corrige sustituciones múltiples (Jukes–Cantor, Kimura), pero es suficiente para marcadores poco saturados. Sobre $D \in \mathbb{R}^{N \times N}$ se aplica aglomeración jerárquica (UPGMA / single linkage).

3. Metodología

3.1. Datos

Proyecto 1. CDS del gen CYCS de *Homo sapiens* (RefSeq NM_018947.6, 318 bases) y *Mus musculus* (NM_007808.5, 318 bases), descargados vía E-utilities. Para los benchmarks se concatenan copias mutadas ($\sim 2\%$ sustituciones aleatorias) hasta longitudes $\{200, 400, 800, 1600, 3200, 6400\}$ bases.

Proyecto 2. Proteínas citocromo c de seis ortólogos descargadas de UniProt: P99999 (Humano), P99998 (Chimpancé), G4XXM2 (Gorila), P62897 (Ratón), P67881 (Gallina) y P00025 (Atún *Katsuwonus pelamis*). Todas las proteínas maduras tienen 104–105 aa.

3.2. Implementación

Sobre la jerarquía **Aligner** de la PC2 se añaden tres módulos sin modificar el código existente (principio Open/Closed): **nw_two_rows.py** (primitiva $O(n)$ que devuelve la última fila de la matriz NW), **hirschberg.py** (clase **HirschbergAligner** con la misma interfaz **align()** que **NeedlemanWunsch**) y **phylogeny.py** (matriz de distancias 6×6 reutilizando **NeedlemanWunsch**). La memoria se mide con **memory_profiler.memory_usage** (sampling 20 ms, delta sobre baseline). Los dendrogramas se dibujan con **scipy.cluster.hierarchy** sólo para visualización, como permite la consigna.

4. Resultados

4.1. Proyecto 1: Hirschberg vs. NW clásico

Corrección. Sobre los 318 bases del CDS de citocromo c (humano vs. ratón, matriz SIMPLE $+1/-1$, $g = -1$), ambas implementaciones devuelven *exactamente* el mismo score, longitud e identidad: score = 260, $L = 320$ posiciones, identidad 90,6 %. (Las cadenas concretas pueden diferir en empates de traza, fenómeno conocido cuando existen varios alineamientos óptimos.)

Tabla 1: Comparacion de tiempo y memoria entre NW clasico y Hirschberg para longitudes crecientes. Memoria reportada es el delta sobre el baseline del proceso Python (medido con `memory_profiler`).

L (bases)	t_{NW} (ms)	t_{HB} (ms)	Δm_{NW} (MiB)	Δm_{HB} (MiB)
200	52.0	67.5	2.01	0.00
400	55.0	99.0	2.07	0.00
800	154.7	324.7	15.73	0.00
1600	584.5	1383.2	78.79	0.00
3200	2321.8	5621.4	357.57	0.00
6400	9274.0	23658.4	1429.65	0.00




Figura 1: Tiempo de ejecución (izq., escala log-log) y memoria adicional pico (der.) en función de la longitud de las secuencias. Ambos algoritmos muestran pendiente cuadrática en tiempo, pero NW clásico crece también de forma cuadrática en memoria mientras que Hirschberg se mantiene en cero.

Benchmark. La Tabla 4.1 y la Figura 1 resumen el comportamiento sobre tamaños crecientes. Se confirma empíricamente la complejidad teórica:

Lectura. Hirschberg es $\sim 2,5\times$ más lento (constante derivada de la recursión, en la teoría es $2\times$; el extra viene de la implementación en Python puro). En cambio, para 6400 bases NW consume **1.43 GiB** adicionales, mientras Hirschberg permanece dentro del baseline ($\Delta \approx 0$). El cruce de viabilidad ocurre alrededor de 3200 bases en mi laptop, pero el patrón es: NW clásico es inutilizable a partir de unos pocos miles de bases en cualquier máquina de uso general.

Casos biológicos donde Hirschberg es crítico. Alineamiento de *transcritos largos* (>5 kb, frecuentes en eucariotas), de cDNAs reconstruidos contra el genoma de referencia (10^4 – 10^5 bases), o cualquier pipeline pensado para correr en máquinas con memoria acotada (clústers compartidos, contenedores con límites de RAM). En la práctica las herramientas modernas (**minimap2**, **BWA**) usan extensiones más sofisticadas, pero la idea de fondo es la misma: *no almacenar* la matriz $O(mn)$.

4.2. Proyecto 2: filogenia del citocromo c

Matriz de distancias. La Tabla 4.2 muestra la matriz D obtenida con NW + BLOSUM62, $g = -4$. Los tres primates (Humano, Chimpancé, Gorila) tienen identidad 100 % entre ellos, resultado biológicamente *correcto*: el citocromo c maduro es idéntico en los Hominidae [6]. Las distancias crecen monótonamente con la separación evolutiva esperada.

Validación contra Bio.Align.PairwiseAligner. Los 15 pares fueron re-alineados con la implementación de Biopython (NW global, mismo BLOSUM62, mismo gap lineal -4). **Los 15 pares produjeron el mismo score y la misma identidad:** Humano–Chimp 565/100 %, Humano–Ratón

Tabla 2: Matriz de distancias (%) entre las 6 especies. $d_{ij} = 100 - \text{identidad}_{ij}$ del alineamiento global Needleman–Wunsch con BLOSUM62.

	Humano	Chimpance	Gorila	Raton	Gallina	Atun
Humano	0.0	0.0	0.0	8.6	12.4	20.0
Chimpance	0.0	0.0	0.0	8.6	12.4	20.0
Gorila	0.0	0.0	0.0	8.6	12.4	20.0
Raton	8.6	8.6	8.6	0.0	7.6	15.2
Gallina	12.4	12.4	12.4	7.6	0.0	16.2
Atun	20.0	20.0	20.0	15.2	16.2	0.0

522/91,4 %, Humano–Gallina 507/87,6 %, Humano–Atún 458/80,0 %, Ratón–Gallina 531/92,4 %, Gallina–Atún 478/83,8 %, etc. Esto confirma que nuestra implementación artesanal de NW es funcionalmente equivalente a la estándar de Biopython.

Dendrograma. La Figura 2 presenta dos topologías obtenidas a partir de la misma matriz: UPGMA (average linkage) y vecino más cercano (single linkage). El cluster (Humano, Chimpancé, Gorila) aparece como un único nodo a distancia 0 en ambos métodos (los tres son indistinguibles a nivel de citocromo c). El Atún (*Katsuwonus pelamis*) se posiciona como outgroup, consistente con la filogenia conocida vertebrado/pez.




Figura 2: Dendrogramas reconstruidos desde la matriz de distancias por NW+BLOSUM62 con dos métodos de linkage. El cláde primate (id=100 %) colapsa a distancia 0. El atún se separa como outgroup.

Concordancia con el árbol evolutivo conocido. El árbol esperado para estas seis especies es ((((*Humano*, *Chimp*, *Gorila*), *Ratón*), *Gallina*), *Atún*): una jerarquía anidada (primates) $\subset$ mamíferos $\subset$ amniotas $\subset$ vertebrados con mandíbula. **Nuestro árbol coincide parcialmente.** Los primates sí se agrupan correctamente; el atún es correctamente el outgroup más distante. Sin embargo, las distancias internas muestran una *anomalía*: $d(\text{Ratón}, \text{Gallina}) = 7,6$ es *menor* que $d(\text{Humano}, \text{Ratón}) = 8,6$, lo que hace que UPGMA agrupe (Ratón, Gallina) antes que (Primates, Ratón). La topología correcta uniría los mamíferos primero (primates + ratón) y después la gallina.

5. Discusión

5.1. Por qué falla el citocromo c

La anomalía no es de la implementación (los scores coinciden con Biopython) sino del *marcador molecular*. Tres razones documentadas: **(1) Saturación:** el citocromo c es una proteína muy con-

servada ($\sim 30\%$ de posiciones variables); a divergencias >300 Ma (amniota/teleosteo) la mayoría de posiciones variables ya han sufrido múltiples sustituciones, subestimando la distancia. **(2) Tasa heterogénea:** el linaje aviar evoluciona más lento que el de roedores [3], comprimiendo Ratón–Gallina. **(3) Modelo ingenuo:** $d = 100(1 - p)$ ignora reversiones; correcciones de Jukes–Cantor (ADN) o Poisson ($d = -\ln p$ para proteínas) amplifican las distancias grandes y corrigen parte de la paradoja.

5.2. Limitaciones

Gap lineal: se usó penalización constante; la práctica estándar emplea *affine gap penalty* (Gotoh [5]). Extender Hirschberg a gaps afines requiere tres pares de filas (Myers–Miller). **Python puro:** la constante $2\times$ se infla por overhead del intérprete; NumPy/Cython recortaría esta brecha. **Clustering:** *scipy* ofrece UPGMA/single linkage pero no *Neighbor-Joining*, preferible para datos no ultramétricos. **Sin bootstrap:** la confianza en cada clade no se cuantifica.

6. Conclusiones

(1) El algoritmo de Hirschberg implementado sobre la jerarquía OO de la PC2 reproduce *exactamente* el score óptimo de NW con memoria $O(\min(m, n))$: para 6400 bases la reducción es de 1.4 GiB $\rightarrow$ 0 MiB adicionales, a costa de $\sim 2,5\times$ en tiempo. (2) La matriz de distancias por NW+BLOSUM62 sobre seis ortólogos de citocromo c agrupa correctamente los primates y separa el atún como out-group, pero falla en la topología interna mamíferos/aves por saturación y heterogeneidad de tasa del marcador. (3) Los 15 pares fueron re-validados contra *Bio.Align.PairwiseAligner* obteniendo el mismo score e identidad en *todos* los casos. (4) Cambiar el algoritmo (NW $\rightarrow$ Hirschberg) no altera la respuesta biológica; cambiar el marcador sí. El algoritmo asegura optimalidad respecto a una función objetivo; la interpretación biológica depende del marcador, la matriz y el modelo de distancia.

Referencias

- [1] Hirschberg, D. S. (1975). A linear space algorithm for computing maximal common subsequences. *Communications of the ACM*, 18(6), 341–343.
- [2] Needleman, S. B., & Wunsch, C. D. (1970). A general method applicable to the search for similarities in the amino acid sequence of two proteins. *Journal of Molecular Biology*, 48(3), 443–453.
- [3] Dayhoff, M. O., Schwartz, R. M., & Orcutt, B. C. (1978). A model of evolutionary change in proteins. *Atlas of Protein Sequence and Structure*, 5(3), 345–352.
- [4] Henikoff, S., & Henikoff, J. G. (1992). Amino acid substitution matrices from protein blocks. *PNAS*, 89(22), 10915–10919.
- [5] Gotoh, O. (1982). An improved algorithm for matching biological sequences. *Journal of Molecular Biology*, 162(3), 705–708.
- [6] Margoliash, E., & Smith, E. L. (1965). Structural and functional aspects of cytochrome c in relation to evolution. *Evolving Genes and Proteins*, 221–242.
- [7] Cock, P. J. A., et al. (2009). Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11), 1422–1423.
- [8] Espinoza, F. (2026). *Alineamiento de pares de secuencias biológicas: NW y SW con matrices SIMPLE/PAM/BLOSUM* (Informe PC2, CC0F3 – Biología Computacional, UNI).