

Optimización espacial de Needleman–Wunsch y filogenia molecular del citocromo c

Examen Parcial – CC0F3 Biología Computacional

Franklin Espinoza Pari

20210135D

Mayo de 2026

Universidad Nacional de Ingeniería

Contexto: PC2 $\rightarrow$ Parcial

De dónde partimos

Base PC2: Needleman–Wunsch (global) + Smith–Waterman (local) en Python OO con *Template Method* y *Strategy*; matrices SIMPLE, PAM y BLOSUM.

Dos preguntas del parcial, resueltas reutilizando esa base:

- **Proyecto 1.** El límite práctico de NW es la *memoria*: $O(mn)$. $\Rightarrow$ **algoritmo de Hirschberg** para llegar a $O(\min(m, n))$.
- **Proyecto 2.** Distancia evolutiva por pares con NW $\Rightarrow$ **matriz de distancias y dendrograma** para 6 ortólogos de citocromo c.

Datos reales (NCBI/UniProt, no inventados): CDS de CYCS humano/ratón y proteínas citocromo c de Humano, Chimpancé, Gorila, Ratón, Gallina, Atún.

Proyecto 1: Hirschberg

El problema de memoria de NW

La recurrencia

$$H_{i,j} = \max\{H_{i-1,j-1} + s(\sigma_1[i], \sigma_2[j]), H_{i-1,j} + g, H_{i,j-1} + g\}$$

solo depende de la fila anterior $\Rightarrow$ el **score** cabe en $O(n)$ (dos filas).

Pero el traceback necesita la matriz completa. Para un cromosoma de $10^5 \times 10^5$ celdas eso son ~ 40 GiB en enteros de 32 bits: inviable.

Idea de Hirschberg (1975)

Divide-and-conquer: parte σ_1 por la mitad $i^* = m/2$ y busca j^* tal que $j^* = \arg \max_j (F[j] + B[n-j])$, con F, B calculados en $O(n)$ memoria. Recurre sobre las dos mitades y concatena. **Tiempo** $O(mn)$, **memoria** $O(\min(m, n))$.

Implementación sobre la jerarquía de la PC2

Tres archivos nuevos, **cero modificaciones** a la PC2 (Open/Closed):

- `parcial/nw_two_rows.py` – primitiva $O(n)$ que devuelve la *última fila* de NW.
- `parcial/hirschberg.py` – clase `HirschbergAligner` con la misma interfaz `align()` que `NeedlemanWunsch`.
- `parcial/benchmark.py` – medición de tiempo y memoria pico con `memory_profiler`.

Validación de corrección (CDS humano vs ratón, 318 bases):

	score	longitud	identidad
NW clásico	260	320	90.6 %
Hirschberg	260	320	90.6 %

Score idéntico; la cadena exacta puede diferir en empates de traceback (varios alineamientos óptimos).


Benchmark: tiempo y memoria

L (bases)	t_{NW} (ms)	Δm_{NW} (MiB)	Δm_{HB} (MiB)
200	52	2.0	0.0
400	55	2.1	0.0
800	155	15.7	0.0
1600	585	78.8	0.0
3200	2322	357.6	0.0
6400	9274	1429.7	0.0

NW $\rightarrow$ **1.4 GiB** para 6400 bases.

Hirschberg $\rightarrow$ baseline (0 MiB delta).

Tiempo: HB es $\sim 2,5\times$ más lento.



Casos biológicos donde Hirschberg es crítico

- **Transcritos largos.** mRNAs eucariotas >5 kb, alineamiento cDNA vs. genoma de referencia (10^4 – 10^5 bases).
- **Máquinas con memoria acotada.** Clústers compartidos, contenedores Docker con límites de RAM.
- **Mapecto de reads largos.** La idea de fondo de minimap2 y BWA: *nunca* materializar la matriz $O(mn)$.

Mensaje: la complejidad temporal $O(mn)$ es idéntica entre ambas versiones; la diferencia es exclusivamente **memoria**. Para mn grande, la memoria es el cuello de botella real.

Proyecto 2: filogenia del citocromo c

6 ortólogos de citocromo c de UniProt (104–105 aa):

Etiqueta	UniProt	Organismo
Humano	P99999	<i>Homo sapiens</i>
Chimpancé	P99998	<i>Pan troglodytes</i>
Gorila	G4XXM2	<i>Gorilla gorilla</i>
Ratón	P62897	<i>Mus musculus</i>
Gallina	P67881	<i>Gallus gallus</i>
Atún	P00025	<i>Katsuwonus pelamis</i>

Pipeline:

1. NW + BLOSUM62, gap -4 sobre cada par (i, j) .
2. Distancia $d_{ij} = 100 - \text{identidad}_{ij}$.
3. Matriz $D \in \mathbb{R}^{6 \times 6}$, simétrica, $d_{ii} = 0$.
4. Dendrograma con UPGMA y single linkage (scipy, solo para dibujar).

Matriz de distancias 6×6

	Humano	Chimp	Gorila	Ratón	Gallina	Atún
Humano	0.0	0.0	0.0	8.6	12.4	20.0
Chimpancé	0.0	0.0	0.0	8.6	12.4	20.0
Gorila	0.0	0.0	0.0	8.6	12.4	20.0
Ratón	8.6	8.6	8.6	0.0	7.6	15.2
Gallina	12.4	12.4	12.4	7.6	0.0	16.2
Atún	20.0	20.0	20.0	15.2	16.2	0.0

Observaciones:

- Primates entre sí: **identidad 100 %** (citocromo c maduro es idéntico en los Hominidae, dato biológico real).
- Distancias monótonamente crecientes con la separación evolutiva.
- **Anomalía:** $d(\text{Ratón}, \text{Gallina}) = 7,6 < d(\text{Humano}, \text{Ratón}) = 8,6$.

Validación contra Biopython (sustituto de BLAST)

Los 15 pares fueron re-alineados con `Bio.Align.PairwiseAligner` (NW global, mismo BLOSUM62, mismo gap lineal -4).


Resultado: coincidencia exacta en score y % identidad para los 15 pares.

Par	Score NW	%id NW	Score Bio	%id Bio
Humano vs Chimpancé	565	100.0	565	100.0
Humano vs Ratón	522	91.4	522	91.4
Humano vs Gallina	507	87.6	507	87.6
Humano vs Atún	458	80.0	458	80.0
Ratón vs Gallina	531	92.4	531	92.4
Gallina vs Atún	478	83.8	478	83.8

⇒ Nuestra implementación de NW de la PC2 es **funcionalmente equivalente** a la estándar de Biopython para gap lineal.

Dendrograma

Arbol filogenetico - Citocromo C (NW + BLOSUM62)



UPGMA (izq.) y single linkage (der.). El clade primate colapsa a distancia 0; el atún es outgroup.

¿Coincide con el árbol evolutivo conocido?

Topología esperada:

$(((((\text{Humano}, \text{Chimp}, \text{Gorila}), \text{Ratón}), \text{Gallina}), \text{Atún}))$

Primates $\subset$ mamíferos $\subset$ amniotas $\subset$ vertebrados con mandíbula.

Resultado: coincide *parcialmente*.

- ✓ Primates agrupados correctamente (distancia 0 entre ellos).
- ✓ Atún identificado correctamente como outgroup.
- ✗ La topología interna falla: UPGMA agrupa (Ratón, Gallina) *antes* que (Primates, Ratón), porque $d(\text{Ratón}, \text{Gallina}) = 7,6 < d(\text{Humano}, \text{Ratón}) = 8,6$.

No es un bug del código (Biopython da exactamente las mismas distancias): es un problema del *marcador molecular*.

¿Por qué falla el citocromo c?

1. Saturación del marcador

Solo $\sim 30\%$ de las posiciones varían. A divergencias > 300 Ma (amniota/teleosteo), la mayoría ya han mutado múltiples veces $\rightarrow$ la identidad observada subestima la distancia real.

2. Tasa heterogénea

El linaje aviar (Gallina) evoluciona más lento que el de los roedores (Dayhoff 1978) $\rightarrow$ Ratón–Gallina aparece artificialmente comprimido.

3. Modelo de distancia ingenuo

$d = 100(1 - p)$ no corrige reversiones ni sustituciones múltiples. Correcciones de Jukes–Cantor (ADN) o Poisson para proteínas ($d = -\ln p$) amplifican las distancias grandes y suelen corregir la paradoja.

Cierre

Conclusiones

1. **Hirschberg = score óptimo de NW con memoria** $O(\min(m, n))$. Para 6400 bases: 1.4 GiB $\rightarrow$ 0 MiB adicionales, costo $\sim 2.5\times$ en tiempo.
2. **Filogenia con NW + BLOSUM62** reproduce el clade primate y el outgroup atún, pero falla en la topología interna mamíferos/aves por saturación y heterogeneidad de tasa del citocromo c.
3. **Validación:** 15/15 pares coinciden en score y % identidad contra `Bio.Align.PairwiseAligner`.
4. **Lectura central:** cambiar el *algoritmo* (NW $\rightarrow$ Hirschberg) no altera la respuesta biológica; cambiar el *marcador* sí. El algoritmo asegura optimalidad respecto a una función objetivo; la interpretación biológica depende del marcador, la matriz y el modelo de distancia.

Gracias.

`github.com/franklinep/-CC0F3-Biologia_Computacional`